

بسم الله الرحمن الرحيم

چگونه داده های طولی را تمیز کنیم؟

زهرا عسگری

استاد راهنما : دکتر احسان بهرامی سامانی



دانشگاه شهید بهشتی

خرداد ۱۴۰۵

پیش‌گفتار

امروزه تحلیل داده در بسیاری از حوزه‌ها بیش از پیش حائز اهمیت واقع شده و نقش راهگشای خود را نشان می‌دهد. در این میان، بخش مهمی از فرایند تحلیل داده که دانشمندان و تحلیلگران با آن مواجه‌اند و در پیش‌بینی‌ها و تحلیل‌های آماری تأثیر بسزایی دارد، تمیز کردن داده‌ها (data cleaning) است.

در فرایند تمیز کردن داده، یکی از مهم‌ترین چالش‌ها برخورد با داده‌های گمشده است که به علل مختلفی در مجموعه داده ثبت نشده‌اند.

همچنین با انواع مختلفی از ساختارهای داده روبه‌رو می‌شویم. برای برخورد مناسب با داده‌های گمشده، ابتدا باید ساختار داده را مشخص کنیم.

مطالعات طولی یکی از انواع پرکاربرد مطالعات آماری است که در نقطه مقابل مطالعات مقطعی قرار دارد. در مطالعات مقطعی، داده را از یک جامعه در یک نقطه مشخص زمانی جمع‌آوری می‌کنیم، حال آنکه در یک مطالعه‌ی طولی، به طور مکرر و در یک بازه‌ی زمانی طولانی از همان نمونه داده جمع‌آوری می‌کنیم.

مطالعات طولی در بسیاری از حوزه‌ها از جمله ارزیابی رابطه بین عوامل خطر و توسعه بیماری، و همچنین نتایج درمان‌ها در بازه‌های زمانی، مطالعات روان‌شناسی و جنبه‌های مختلف دیگر مفید هستند.

در پژوهش حاضر، به بررسی راه‌حل‌های ارائه‌شده برای تمیز کردن داده‌های طولی و برطرف کردن چالش‌های روبه‌رو شدن با داده‌های گمشده در یک مجموعه داده طولی می‌پردازیم.

کلیات پژوهش، بیان مسئله و اهداف ان

در این قسمت ابتدا کلیات پژوهش را برای خوانندگان محترم شرح می دهیم و سپس به اهمیت مسئله و اهداف می پردازیم همچنین در انتهای این بخش مفاهیم و تعاریف اساسی را به تفصیل شرح خواهیم داد

۱-۱- کلیات پژوهش

در پژوهش حاضر تعریفی از داده‌هایی با ساختار طولی ارائه خواهیم داد و همچنین به بررسی انواع گمشدگی در داده می‌پردازیم.

همچنین پیشینه‌ای از بحث و راه‌حل‌های ارائه‌شده برای حل این چالش را مرور خواهیم کرد.

در ابتدا الگوریتم‌ها و روش‌های چگونگی برخورد با داده‌های گمشده در داده‌های طولی را ارائه خواهیم نمود.

سپس کدهای مربوطه به الگوریتم‌ها را بیان می‌کنیم و در نهایت الگوریتم‌ها را روی یک مجموعه داده واقعی پیاده‌سازی می‌کنیم که به عنوان ابزار کمکی از نرم‌افزار R استفاده خواهیم نمود.

۱-۱-۱- بیان اهمیت و ضرورت مسئله

قسمت بسیار زیادی از زمان یک تحلیلگر داده صرف تمیز کردن داده می‌شود. در این میان مواجهه با داده‌های گمشده امری اجتناب‌ناپذیر در تحلیل‌های آماریست.

روش برخورد تحلیلگران با داده‌های گمشده نیز از اهمیت بسیاری برخوردار است. در برخی مواقع حذف داده‌های گمشده پیشنهاد می‌شود، اما در بسیاری از موقعیت‌ها با حذف داده‌های ناقص به نتایج کاملاً جهت‌دار و غیردقیق می‌رسیم که عملاً تحلیل ما را نامعتبر می‌سازد.

به‌خصوص در داده‌های طولی در بسیاری از مواقع به داده‌های گمشده برمی‌خوریم که به علل مختلفی در مجموعه داده حضور ندارند. برای مثال در یک مطالعه پزشکی که نمونه‌ها باید در نوبت‌های مکرر به پزشک مراجعه کنند ممکن است به دلیل فوت شخص یا عدم حضور فرد در زمان مقرر در مطب پزشک با تعداد قابل توجهی داده‌ی گمشده روبه‌رو شویم.

در مواردی که حذف داده‌ها ناقص منجر به نامعتبر شدن تحلیل می‌شود روش‌های جانهی (Imputation) پیشنهاد شده‌اند.

Michael J. Daniels و Joseph W. Hogan در کتابشان تحت عنوان داده‌های گمشده در مطالعات طولی (۲۰۰۸) برای نشان دادن کاربردی بودن روش‌هایشان با توجه به نوع گمشدگی روی مجموعه داده‌های متفاوت و واقعی الگوریتم‌های پیشنهادی‌شان را پیاده‌سازی و مقایسه کرده‌اند.

با توجه به کاربرد مطالعات طولی به‌خصوص در پزشکی آن‌ها روی مجموعه داده‌های بالینی کار کرده و نتایج بسیار مفید و جذابی را در اختیار خوانندگان قرار می‌دهند.

۱-۱-۲- اهداف و روش تحقیق

این پژوهش در دو بخش انجام گرفته است. بخش اول پردازش و ارائه روش‌ها و الگوریتم‌های مناسب در برخورد با داده‌های گمشده در مطالعات طولی می‌پردازد و بخش دوم اختصاص به پیاده‌سازی الگوریتم‌ها روی یک مجموعه داده واقعی دارد. همچنین انواع گمشدگی به تفصیل توضیح داده خواهد شد و متناسب با نوع گمشدگی راه‌حل و روش‌های مختلفی یا پیشنهاد حذف داده‌ی ناقص ارائه خواهد شد. قابل ذکر است با توجه به مطالعات انجام گرفته به دلیل پیچیده بودن ساختار این نوع داده تاکنون تمامی روش‌ها دارای کمبودها و معایبی هستند که در ادامه ذکر می‌کنیم و بهینه‌ترین روش‌ها نیز معرفی خواهند شد.

۱-۲- مفاهیم و تعاریف اساسی

۱-۲-۱- مطالعات طولی

و سپس به طور مکرر (baseline) در یک مطالعه طولی هر واحد آزمایشی یا مشاهده‌ای در نقطه مبنا

در طول زمان اندازه‌گیری می‌شود.

در این نوع مطالعه برای رسیدن به سطح مشابهی از توان آماری (statistical power) معمولاً به تعداد کمتری از افراد نیاز است.

مطالعات طولی در مقایسه با مطالعات مقطعی مزایای بسیاری دارند، به‌ویژه از نظر فراهم کردن پایه‌ای قوی برای استنباط علی (causal inference). بنابراین تعجب‌آور نیست که سطح پیچیدگی آماری لازم برای تحلیل داده‌های طولی نیز پیشرفته‌تر باشد.

با وجود این مزایا، داده‌های طولی بدون چالش نیستند.

پرداختن به داده‌های گمشده (missing data) در مطالعات طولی نقش بسیار مهم‌تری نسبت به مطالعات مقطعی دارد.

۱-۲-۲- داده‌های گمشده

در فرایند جمع‌آوری داده ممکن است به علل مختلفی برخی مشاهدات یا متغیرها در مجموعه داده ثبت نشوند. این مسئله می‌تواند به علت عدم پاسخگویی به تمام سؤالات یک نظرسنجی یا نقص در جمع‌آوری داده‌ها و دلایل دیگری باشد که در ادامه به آن می‌پردازیم.

گمشدگی در مجموعه داده می‌تواند منجر به سوگیری در نتایج به دست آمده و کاهش اعتبار تحلیل‌های آماری شود. فلذا تلاش برای جلوگیری از وجود داده‌های گمشده در حین جمع‌آوری و نیز ارائه راه حل برای رفع این مشکل از اهمیت زیادی برخوردار است.

۱-۲-۳- مکانیزم‌های گمشدگی

روبین (۱۹۷۶) میان سه سازوکار مهم تمایز قائل شد. هنگامی که گمشدگی با داده‌ها نامرتب باشد، گمشدگی را گمشده کاملاً تصادفی (missing completely at random; MCAR) می‌نامند.

وقتی گمشدگی داده‌ها کاملاً تصادفی (MCAR) باشد، در واقع می‌توان آن را در تحلیل نادیده گرفت.

هنگامی که گم‌شدگی به داده‌های مشاهده‌شده وابسته باشد و، با در نظر گرفتن داده‌های مشاهده‌شده، به داده‌های مشاهده‌نشده وابسته نباشد، سازوکار، گم‌شده تصادفی (missing at random; MAR) است.

سازوکاری که در آن گم‌شدگی به داده‌های مشاهده‌نشده وابسته باشد، شاید علاوه بر داده‌های مشاهده‌شده، گم‌شده نه به‌طور تصادفی (missing not at random; MNAR) نامیده می‌شود.

برای فهم دقیق‌تر مکانیزم MNAR به مثال زیر توجه کنید.

در یک مطالعه طولی درباره افسردگی افرادی که افسردگی شدیدتری دارند ممکن است کمتر در ویزیت‌های بعدی شرکت کنند.

شدت واقعی افسردگی آن‌ها ثبت نشده چون در مطالعه حضور ندارند. بنابراین احتمال گم شدن شدن به مقدار واقعی ولی مشاهده‌نشده‌ی متغیر پاسخ وابسته است. پس داده‌ها MNAR هستند و مکانیزم گم‌شدگی قابل چشم‌پوشی نیست.

۱-۲-۴- الگوهای گم‌شدگی


۱-۲-۴-۱- الگوی یکنواخت (monotone)

گفته می‌شود داده‌ها از الگوی گم‌شدگی یکنواخت (monotone missing pattern) پیروی می‌کنند اگر بتوان آن‌ها را به گونه‌ای مرتب کرد که وقتی برای یک فرد یک مشاهده از دست می‌رود، تمام مشاهده‌های بعدی نیز گم‌شده باشند. یکی از نمونه‌های این حالت ریزش (dropout) است؛ یعنی زمانی که یک بیمار مطالعه را ترک می‌کند و دیگر باز نمی‌گردد.

به عنوان مثال فرض کنید در یک مطالعه بعضی شرکت کنندگان به علت فوت، مهاجرت یا قطع همکاری با پژوهشگران تا انتهای مطالعه حضور نداشته باشد.

۱-۲-۴-۲- الگوی غیریکنواخت (non-monotone)

ممکن است یک آزمودنی در یک بازه پیگیری غایب باشد و سپس در یکی از بازه‌های بعدی دوباره اندازه‌گیری شود که این امر منجر به ایجاد الگوهای داده‌های گمشده غیریکنوا (Nonmonotone missing data patterns) می‌شود. چنین داده‌هایی چالش مدل‌سازی قابل توجهی را برای آماردان ایجاد می‌کنند.



شکل ۱-۱- مقایسه گمشدگی یکنواخت (با الگوی ریزش) و گمشدگی غیریکنواخت

۱-۲-۵- جانهی (imputation)

به فرآیند پر کردن داده‌های گمشده در یک نمونه، از طریق برآورد مقادیر احتمالی بر اساس تحلیل داده‌های موجود، جانهی (imputation) گفته می‌شود. این فرآیند شامل روش‌های مختلفی است که هدف آن‌ها تعیین جانشین‌های معقول برای اطلاعاتِ غایب است

مروری بر پیشینه مطالعات طولی و چالش‌های مرتبط

۱-۲- مطالعات طولی امکان بررسی تغییرات درون فردی را در طول زمان فراهم می‌کنند (Hedeker & Gibbons, ۲۰۰۶). مثلاً بررسی اینکه آیا داروی فشار خون در طول یک بازه‌ی زمانی مشخص، تأثیر مثبتی روی افراد حاضر در مطالعه داشته است؟ از این‌رو نقش مطالعات طولی به‌خصوص در پژوهش‌های پزشکی و اپیدمیولوژی انکارناپذیر است. چالش اصلی در تحلیل داده‌های طولی، برخورد با داده‌های گمشده است. همان‌طور که در بخش قبل اشاره کردیم، گمشدگی انواعی دارد. متخصصان و پژوهشگران آماری تاکنون روش‌هایی برای برخورد با مقادیر گمشده پیشنهاد کرده‌اند که هر کدام نقاط ضعف و نقاط قوتی دارند؛ البته باید دقت کنیم که هر کدام از این روش‌ها با توجه به مکانیسم‌های گمشدگی، مورد استفاده قرار خواهند گرفت.

ساده‌ترین رویکرد پیشنهادشده برای گمشدگی یکنواخت (dropout) تاکنون، «تحلیل موارد کامل» (Complete-case analysis) می‌باشد. در این رویکرد، تحلیل را فقط با آزمودنی‌هایی انجام می‌دهیم که تا پایان پژوهش حضور داشته‌اند و افراد با داده‌های گمشده به‌طور کامل از نمونه حذف می‌شوند؛ این امر می‌تواند منجر به نتایج نادرست شود (Hedeker & Gibbons, ۲۰۰۶).

رویکرد ساده‌ی بعدی «آخرین مشاهده منتقل شده به جلو» (Last Observation Carried Forward: LOCF) نام دارد. در این روش، آخرین اندازه‌گیری موجود را

به جای تمامی مقادیر گمشده بعد از آن قرار می‌دهیم (Hedeker & Gibbons, ۲۰۰۶).

یکی از معایب این روش، نادیده گرفتن تغییرپذیری تصادفی است (Peter Diggle, ۲۰۰۶, Daniel Farewell).

برای حل این مشکل، روش دیگری به نام جایگذاری چندگانه (Multiple Imputation) پیشنهاد شد. این روش با تکرار فرایند جایگذاری، عدم قطعیت ناشی از داده‌های گمشده را برآورد کرده و در استنباط نهایی لحاظ می‌کند (Rubin, ۱۹۸۷). انتخاب مدل‌های ساده‌تر (مثل MI تحت فرض MAR) اغلب به عنوان یک مصالحه میان دقت تئوری و امکان‌پذیری عملی در پروژه‌های کاربردی ترجیح داده می‌شود.

۲-۲- مدل‌های خطی آمیخته تعمیم‌یافته (GLMM)

مدل‌های خطی آمیخته تعمیم‌یافته (GLMM) به عنوان ابزاری قدرتمند برای تحلیل داده‌های طولی، امکان مدل‌سازی همزمان تغییرات درون فردی و تفاوت‌های بین فردی را فراهم می‌کنند. این مدل‌ها با استفاده از اثرات تصادفی (Random Effects)، وابستگی مشاهدات مکرر برای هر فرد را در طول زمان لحاظ کرده و به متغیرهای پاسخ با توزیع‌های غیرنرمال نیز گسترش می‌یابند. در مواجهه با داده‌های گمشده، GLMMها تحت فرض مکانیسم داده‌های گمشده در تصادف (MAR)، از طریق برآورد درست‌نمایی بیشینه، برآوردهایی سازگار و ناریب ارائه می‌دهند که آن‌ها را به انتخابی استاندارد در تحلیل‌های طولی تبدیل کرده است (Daniels & Hogan, ۲۰۰۸).

۳-۲- رویکردهای مدل سازی در داده‌های گمشده غیر تصادفی (MNAR)

در مدل‌های انتخاب (Selection Models)، خودِ توزیع اصلی داده‌های طولی به‌طور مستقیم مدل می‌شود؛ از این‌رو این رویکرد از نظر شهودی برای بسیاری از پژوهشگران طبیعی‌تر است و مدل کردن مکانیسم گمشدن نیز در آن ساده‌تر انجام می‌شود. با این حال، برای حصول قابلیت شناسایی پارامترها، معمولاً باید محدودیت‌ها و قیود اضافی و تا حدی دلخواه بر مدل اعمال شود، و همواره روشن نیست این قیود دقیقاً چه مفهومی برای داده‌های مشاهده‌نشده دارند (Ibrahim & Molenberghs, ۲۰۰۹).

در مقابل، مدل‌های آمیخته الگو (Pattern-Mixture Models) توزیع داده‌های مشاهده‌نشده را به‌صورت جداگانه برای هر الگوی گمشدگی مدل می‌کنند. مزیت اصلی این رویکرد آن است که فرض‌های مربوط به داده‌های گمشده شفاف‌تر بوده و بررسی حساسیت نتایج نسبت به مشخصات مدل آسان‌تر است. با این حال، پارامترهای مورد علاقه به‌طور مستقیم در دسترس نیستند و برای به‌دست‌آوردن توزیع حاشیه‌ای نهایی باید روی الگوهای مختلف میانگین‌گیری انجام شود. افزون بر این، محاسبات مورد نیاز در این رویکرد می‌تواند بسیار پیچیده و از نظر محاسباتی سنگین باشد (Ibrahim & Molenberghs, ۲۰۰۹).

۴-۲- روش‌های بیزی

روش‌های بیزی در تحلیل داده‌های طولی، رویکردی انعطاف‌پذیر برای مواجهه با داده‌های گمشده ارائه می‌دهند. در این چارچوب، استنباط آماری از طریق ترکیب اطلاعات پیشین (Prior) با داده‌های مشاهده‌شده و استخراج توزیع پسین (Posterior) حاصل می‌شود. از جمله مزایای اصلی این روش، سادگی در پیاده‌سازی فرآیند جایگذاری برای داده‌های

گمشده است که از طریق افزودن گام‌های نمونه‌گیری به الگوریتم‌های شبیه‌سازی (مانند نمونه‌گیر گیبس) امکان‌پذیر می‌گردد (Daniels & Hogan, ۲۰۰۸). با این حال، استفاده از این روش نیازمند توجه دقیق به انتخاب توزیع‌های پیشین است؛ چرا که به‌ویژه در شرایط داده‌های گمشده‌ی غیرقابل‌چشم‌پوشی (MNAR)، نتایج ممکن است نسبت به این انتخاب‌ها حساس باشند و نیازمند تحلیل‌های دقیق‌تری باشند.

روش ها و الگوریتم های برخورد با داده های گمشده در مطالعات طولی

۱-۳- روش آخرین مشاهده به جلو منتقل شده (LOCF)

در روش LOCF، مقادیر گمشده ی هر فرد با استفاده از آخرین مقدار مشاهده شده ی همان فرد جایگذاری می شوند. به عبارت دیگر، اگر برای یک آزمودنی در زمان های پیگیری داده ای در دسترس نباشد، آخرین مقدار ثبت شده به زمان های بعدی «حمل» (Carry Forward) می شود.

هرچند LOCF به دلیل سادگی در پیاده سازی به طور گسترده در کارآزمایی های بالینی سنتی استفاده شده است، اما به دلیل ناتوانی در بازنمایی تغییرات واقعی افراد در طول زمان، منجر به سوگیری (Bias) در برآورد پارامترها می شود. از این رو، اعتبار نتایج حاصل از آن همواره مورد تردید متخصصان آمار است و توصیه می شود در تحلیل های مدرن با احتیاط فراوان استفاده شود یا جایگزین گردد.

۲-۳- جایگذاری چندگانه (Multiple Imputation)

یکی از روش های کاربردی و محبوب برای مدیریت داده های گمشده در مطالعات طولی است. این روش که نخستین بار توسط روبین پیشنهاد شد، شامل دو گام اصلی است: نخست، برای مقادیر گمشده، با استفاده از مدلی که بر پایه داده های مشاهده شده برازش شده است، چندین مقدار جایگذاری شده از توزیع پیش بینی آن ها استخراج می شود. این فرایند m بار تکرار می شود تا چندین مجموعه داده کامل تولید شود. سپس، هر یک از این

مجموعه داده‌های کامل با استفاده از مدل تحلیلی اصلی موردنظر تحلیل می‌شوند و در نهایت، برآوردهای حاصل و خطاهای استاندارد آن‌ها با استفاده از قواعد روبین ترکیب می‌شوند تا برآورد نهایی به دست آید.

اعتبار نتایج حاصل از این روش، وابسته به این است که مدل جایگذاری به درستی مشخص شده و با مدل تحلیل اصلی سازگار باشد. همچنین این روش‌ها معمولاً تحت فرض «گمشده به صورت تصادفی» (Missing At Random یا MAR) برآوردهای بدون سوگیری ارائه می‌دهند؛ یعنی فرض می‌شود احتمال گمشده بودن داده‌ها، مشروط بر داده‌های مشاهده شده، مستقل از خود مقادیر گمشده است.

برای پیاده‌سازی جایگذاری چندگانه در داده‌های طولی، دو تصمیم اساسی باید اتخاذ شود: نخست انتخاب رویکرد مدل‌سازی (JM یا FCS) و دوم انتخاب قالب چیدمان داده‌ها (Wide یا Long) جهت اعمال مدل جایگذاری.

۱. رویکردهای مدل‌سازی: JM در برابر FCS

- مدل‌سازی مشترک (Joint Modeling یا JM): در این رویکرد، فرض می‌شود که همه متغیرهای دارای داده گمشده به‌طور همزمان از یک توزیع چندمتغیره مشترک (مانند توزیع نرمال چندمتغیره) پیروی می‌کنند و جایگذاری آن‌ها به‌صورت یکجا انجام می‌شود.

- مشخص‌سازی شرطی کامل (Fully Conditional Specification یا FCS): در این رویکرد، متغیرهای ناقص به‌صورت ترتیبی و با استفاده از مجموعه‌ای از مدل‌های جایگذاری تک‌متغیره جایگذاری می‌شوند؛ به این صورت که برای هر متغیر ناقص، یک مدل شرطی بر اساس سایر متغیرها تعریف شده و این فرایند به‌صورت تکراری انجام می‌گیرد.

۳-۳- مدل خطی آمیخته تعمیم یافته (GLMM)

مدل‌های خطی آمیخته تعمیم یافته (Generalized Linear Mixed Models, GLMM)

یکی از روش‌های مناسب برای تحلیل داده‌های طولی هستند.

در این مدل‌ها، علاوه بر اثرات ثابت (fixed effects) که بیانگر اثر متغیرهای توضیحی در کل جامعه‌اند، اثرات تصادفی (random effects) نیز در نظر گرفته می‌شوند تا همبستگی میان اندازه‌گیری‌های مکرر هر فرد در طول زمان مدل‌سازی شود.

اهمیت GLMM در تحلیل داده‌های طولی از آن جهت است که این مدل می‌تواند انواع مختلف متغیر پاسخ، مانند پاسخ‌های پیوسته، دودویی و شمارشی را در بر گیرد. در نتیجه، برخلاف مدل‌های خطی کلاسیک، محدود به داده‌های نرمال نیست و انعطاف‌پذیری بیشتری در کاربردهای عملی دارد.

در حضور داده‌های گمشده، GLMM به‌خودی‌خود یک روش جانمایی (imputation) نیست، اما تحت فرض گمشدگی از نوع MAR و با استفاده از روش‌های مبتنی بر درست‌نمایی بیشینه (Maximum Likelihood)، می‌تواند با استفاده از داده‌های مشاهده‌شده برآوردهای معتبری از پارامترها ارائه دهد. به‌همین دلیل، این مدل در بسیاری از مطالعات طولی به‌عنوان مدل تحلیلی اصلی پس از اعمال روش‌هایی مانند جایگذاری چندگانه (Multiple Imputation) به کار می‌رود.

با این حال، اگر مکانیسم گمشدگی از نوع MNAR باشد، استفاده از GLMM به‌تنهایی کافی نیست؛ زیرا در این حالت، نادیده گرفتن سازوکار گمشدگی می‌تواند به برآوردهای سوگیرانه منجر شود.

پیاده‌سازی الگوریتم‌های ارائه شده روی مجموعه داده واقعی

۱-۴- پیاده‌سازی الگوریتم‌ها روی داده‌ها با گمشدگی یکنواخت و مکانیزم MAR

در این پژوهش، جهت ارزیابی عملی عملکرد روش‌های مختلف مواجهه با داده‌های گمشده‌ی طولی، از مجموعه‌داده استاندارد محرومیت خواب (sleepstudy) موجود در بسته lme4 در محیط نرم‌افزار R استفاده شده است. این داده‌ها برگرفته از مطالعه‌ی تجربی بلنکی و همکاران (۲۰۰۳) هستند که به بررسی اثر محدودیت شدید خواب بر زمان واکنش افراد می‌پردازد. در این مطالعه، تعداد ۱۸ آزمودنی به مدت ۱۰ روز (از روز ۰ تا روز ۹) تحت مشاهده قرار گرفتند که در این مدت خواب آن‌ها به ۳ ساعت در شب محدود شده بود. متغیر پاسخ پیوسته، میانگین زمان واکنش آزمودنی‌ها در تست‌های روزانه بر حسب میلی‌ثانیه (Reaction) و متغیر طولی یا زمان، تعداد روزهای محرومیت از خواب (Days) است. در حالت کامل، این داده‌ها شامل ۱۸۰ رکورد (۱۸ آزمودنی در ۱۰ بازه زمانی) می‌باشند.

برای مدل‌سازی این داده‌های طولی، از مدل اثرات مختلط خطی (LMM) استفاده گردید. مدل مورد نظر با فرض عرض از مبدأ و شیب تصادفی برای هر آزمودنی تعریف می‌شود

$$Reaction_{ij} = (\beta_0 + b_{0i}) + (\beta_1 + b_{1i})Days_{ij} + \epsilon_{ij}$$

که در آن β_1 نشان‌دهنده‌ی شیب متوسط زمان (تأثیر تعداد روزهای محرومیت بر زمان واکنش در کل جامعه) است و به‌عنوان پارامتر هدف جهت ارزیابی سوگیری (Bias) روش‌ها در نظر گرفته می‌شود.

۱-۱-۴ نحوه‌ی اجرا

جهت ارزیابی دقیق و مقایسه‌ای عملکرد روش‌های مختلف مواجهه با داده‌های گمشده‌ی طولی، در این پژوهش از استراتژی حذف تعمدی داده‌ها بر روی داده‌های کامل مطالعه‌ی خواب استفاده شد. با توجه به اینکه در داده‌های واقعی مکانیسم اصلی گمشدگی مشخص نیست، ایجاد داده‌های ناقص با الگوی کنترل‌شده برای سنجش میزان سوگیری روش‌ها ضروری است.

بدین منظور، مکانیسم گمشدگی تصادفی آزمودنی‌ها تحت فرض MAR و با الگوی ریزش طولی (Dropout) بر روی داده‌های کامل اعمال گردید. در این الگو فرض می‌شود که احتمال خروج یک فرد از مطالعه در هر زمان، به وضعیت متغیر پاسخ او در زمان پیش از آن بستگی دارد. به بیان ساده‌تر، افرادی که در روز قبل زمان واکنش طولانی‌تری (عملکرد ضعیف‌تری) داشتند، با احتمال بیشتری در روز بعد از مطالعه خارج شدند و پس از خروج، مشاهدات بعدی آن‌ها نیز گمشده ثبت گردید.

پس از شبیه‌سازی این داده‌های ناقص، روش‌های آماری حذف کامل (CCA)، انتقال آخرین مشاهده به جلو (LOCF)، جایگذاری چندگانه (MI) و مدل‌های آمیخته خطی

(LMM) بر روی آن پیاده‌سازی شدند تا نتایج حاصل از آن‌ها با مقادیر برآورده شده از داده‌های کامل مقایسه شود.

```
1 required_packages <- c("lme4", "lmerTest", "dplyr", "tidyr", "mice")
2 new_packages <- required_packages[!(required_packages %in% installed.packages()[,"Package"])]
3 if(length(new_packages)) install.packages(new_packages)
4
5 library(lme4)
6 library(lmerTest)
7 library(dplyr)
8 library(tidyr)
9 library(mice)
```

شکل ۴-۱- نصب و فراخوانی کتابخانه های مورد نیاز

```
11 data("sleepstudy")
12 dat_full <- sleepstudy
```

شکل ۴-۲- بارگذاری مجموعه داده sleepstudy

```
18 set.seed(123)
19
20 dat_miss <- dat_full %>%
21   arrange(Subject, Days) %>%
22   group_by(Subject) %>%
23   mutate(
24
25     prob = plogis(-7.5 + 0.015 * lag(Reaction, default = 250)),
26     dropped = cumsum(runif(n()) < prob) > 0,
27     Reaction = ifelse(dropped, NA, Reaction)
28   ) %>%
29   ungroup()
30
```

شکل ۴-۳- ایجاد داده های گمشده dropout با مکانیزم گمشدگی mar

روش حذف کامل آزمودنی‌های دارای نقص، برآورد ۹.۳۰۸ را ارائه داد. اگرچه سوگیری این روش از LOCF کمتر است، اما به دلیل از دست دادن حجم قابل توجهی از نمونه‌ها و کاهش توان آماری، دقت کمتری نسبت به مدل‌های آمیخته و جایگذاری چندگانه دارد. در این قسمت افرادی که دارای حداقل یک داده ی گمشده هستند به طور کامل از مجموعه داده حذف می کنیم سپس مدل را برازش می دهیم.

```
33 subjects_to_keep <- dat_miss %>%
34   group_by(Subject) %>%
35   summarise(has_na = any(is.na(Reaction))) %>%
36   filter(!has_na) %>%
37   pull(Subject)
38
39 cca_dat <- dat_miss %>% filter(Subject %in% subjects_to_keep)
40
41 model_cca <- lmer(Reaction ~ Days + (Days | Subject), data = cca_dat)
42 beta_cca <- fixef(model_cca)["Days"]
43
```

۴-۵- اجرای روش CCA و برازش مدل روی داده های حاصل

۵-۱-۴- روش‌های مبتنی بر جایگذاری (MI و LOCF)

در این دسته از روش‌ها، ابتدا تلاش می‌شود حفره‌های ایجادشده در داده‌ها پر شود و سپس مدل تحلیل روی داده‌های تکمیل‌شده اجرا گردد:

• روش انتقال آخرین مشاهده (LOCF): این روش با برآورد ۷.۹۴۳ و بیشترین میزان سوگیری (۲.۵۲-)، ضعیف‌ترین عملکرد را نشان داد. علت این امر آن است که LOCF با فرض غیرواقع‌بینانه‌ی ثابت ماندن وضعیت آزمودنی پس از خروج از مطالعه، شیب رشد زمان واکنش را به شدت کمتر از مقدار واقعی تخمین می‌زند.

```

45 locf_dat <- dat_miss %>%
46   group_by(Subject) %>%
47   fill(Reaction, .direction = "down") %>%
48   ungroup()
49
50 model_locf <- lmer(Reaction ~ Days + (Days | Subject), data = locf_dat)
51 beta_locf <- fixef(model_locf)["Days"]
52

```

۴-۶- اجرای روش locf در R

• روش جایگذاری چندگانه (MI): در این روش، ۵ نسخه مختلف از داده‌های کامل تولید شد و پس از ترکیب نتایج، برآورد ۹.۴۳۳ به دست آمد. همان‌طور که در جدول مشاهده می‌شود، این روش با سوگیری (Bias) حدود ۱.۰۳-، عملکرد بهتری نسبت به روش‌های ساده‌تری مانند CCA و LOCF داشته است، زیرا توانسته عدم قطعیت ناشی از داده‌های گمشده را تا حدی در برآورد لحاظ کند.

```

54 imp_data <- mice(dat_miss, m = 5, method = "pmm", seed = 123, printFlag = FALSE)
55 fit_mi <- with(imp_data, lmer(Reaction ~ Days + (Days | Subject)))
56 pooled_mi <- pool(fit_mi)
57 beta_mi <- summary(pooled_mi)$estimate[2]
58

```

۴-۷- پیاده‌سازی MI با استفاده از پکیج mice

۴-۱-۶- روش‌های مبتنی بر مدل‌سازی مستقیم (GLMM/LMM)

برخلاف روش‌های قبلی، در رویکرد GLMM (مدل آمیخته خطی تعمیم‌یافته)، فرایند جایگذاری جداگانه‌ای صورت نمی‌گیرد. این مدل با استفاده از تمامی اطلاعات موجود و از

طریق الگوریتم‌های حداکثر درست‌نمایی (Likelihood-based)، مستقیماً روی داده‌های ناقص برازش می‌شود.


نتایج نشان داد که این روش با برآورد ۹.۸۰۲ و کمترین میزان سوگیری (۰.۶۶-)، دقیق‌ترین روش در مواجهه با مکانیسم گمشدگی MAR بوده است. این امر تأیید می‌کند که مدل‌های آمیخته زمانی که فرض گمشدگی تصادفی برقرار باشد، بدون نیاز به جایگذاری‌های پیچیده، برآوردهایی بسیار نزدیک به حقیقت ارائه می‌دهند.

```
60
61 model_glmml <- lmer(Reaction ~ Days + (Days | Subject), data = dat_miss)
62 beta_glmml <- fixef(model_glmml) ["Days"]
63
```

۸-۴- برازش مدل GLMM روی داده‌های ناقص

روش مورد استفاده	β_1 (اثر زمان روی واکنش)	Bias
Full Model	10.467286	0.0000000
CCA(Complete Case Analysis)	9.308550	-1.1587361
LOCF	7.943297	-2.5239894
MI	9.433500	-1.0337864
GLMM	9.802921	-0.6643654

جدول ۸-۴-۱- برآورد اثر مدت زمان خواب روی واکنش



شکل ۴-۹- مقایسه کارایی الگوریتم های مورد استفاده

۴-۲- پیاده سازی الگوریتم ها روی داده ها با گمشدگی غیر یکنواخت و مکانیزم MCAR
 به منظور بررسی رفتار روش های برخورد با داده های گمشده در الگوی گمشدگی غیر یکنواخت (non-monotone)، از دیتاست کلاسیک Orthodont استفاده شده است. این داده ها برگرفته از مطالعه ی Potthoff و Roy (۱۹۶۴) بوده و در بسته ی nlme نرم افزار R موجود است.

این دیتاست شامل اندازه گیری فاصله ی بین مرکز غده ی هیپوفیز و شکاف فک بالا (به میلی متر) برای ۲۷ کودک (۱۶ پسر و ۱۱ دختر) است که در چهار سن ۸، ۱۰، ۱۲ و ۱۴ سالگی اندازه گیری شده اند.

. معرفی دیتاست دوم: Orthodont

به منظور بررسی رفتار روش های برخورد با داده های گمشده در الگوی گمشدگی غیریکنواخت (non-monotone)، از دیتاست کلاسیک Orthodont استفاده شده است. این داده ها برگرفته از مطالعه ی Potthoff و Roy (۱۹۶۴) بوده و در بسته ی nlme نرم افزار R موجود است. این مجموعه داده شامل اندازه گیری فاصله ی بین مرکز غده ی هیپوفیز و شکاف فک بالا (به میلی متر) برای ۲۷ کودک شامل ۱۶ پسر و ۱۱ دختر است که در چهار سن ۸، ۱۰، ۱۲ و ۱۴ سالگی اندازه گیری شده اند.

در این دیتاست، متغیر distance به عنوان پاسخ، متغیر age به عنوان عامل زمان، متغیر Subject به عنوان شناسه ی هر فرد و متغیر Sex به عنوان عامل بین فردی در نظر گرفته می شوند. ویژگی اصلی این داده ها، کامل و متوازن بودن ساختار آن ها در حالت اولیه است؛ به طوری که برای تمام افراد، اندازه گیری ها در هر ۴ مقطع زمانی به طور کامل ثبت شده و مجموعاً ۱۰۸ مشاهده را تشکیل می دهند.

این ویژگی اجازه می دهد تا پس از اعمال گمشدگی مصنوعی، نتایج روش های مختلف جبران داده ها با مقادیر واقعی مقایسه شده و میزان دقت هر روش به طور دقیق ارزیابی شود. همچنین، روند رشد در این داده ها حالتی خطی و صعودی دارد که بستری مناسب برای بررسی مدل های خطی آمیخته و تحلیل اثرات متقابل زمان و جنسیت فراهم می کند.

۱-۲-۴- اجرای کدهای مورد نیاز و تفسیر آن

در این بخش مجموعه داده را در R بارگذاری می کنیم سپس به صورت تجمعی گمشدگی هایی با مکانیزم MCAR در آن ایجاد می کنیم هدف از این کار امکان مقایسه ی کارایی روش های متفاوت با یکدیگر است.

```

1
2 library(nlme)
3 library(zoo)
4 library(dplyr)
5 library(mice)
6
7 d1 <- as.data.frame(Orthodont)
8

```

۴-۱۰- بارگذاری مجموعه داده و فراخوانی کتابخانه های مورد نیاز

```

14 |
15 set.seed(123)
16
17 d2 <- d1
18 d2$distance[sample(1:nrow(d2), 22)] <- NA

```

۴-۱۱- ایجاد ۲۰ درصد گمشدگی در داده ها به صورت کاملاً تصادفی

در ادامه برای مقایسه کارایی روش ها یک مدل را روی داده های کامل و همچنین پس از پیاده سازی روش های برخورد با داده های گمشده روی داده ها جدید نیز برآزش می دهیم تا به این پرسش پاسخ دهیم که کدام برآورد به مقدار اصلی ما نزدیک تر است

از مدل رگرسیون خطی استفاده می کنیم:

$$distance_i = \beta_0 + \beta_1 age_i + \beta_2 Sex_i + \varepsilon_i$$

پارامترهای β_0 ، β_1 و β_2 به ترتیب مقدار پایه فاصله دندان، اثر سن و اثر جنسیت بر فاصله دندان را برآورد می کنند

۴-۲-۲- مدل مرجع (Full Model)

```
11  
12 m_full <- lm(distance ~ age + Sex, data = d1)  
13
```

۴-۱۲- برآزش مدل رگرسیون خطی روی داده های کامل

این مدل به عنوان معیار مرجع استفاده شد تا نتایج LOCF، CCA و MI با آن مقایسه شوند.

۴-۲-۳- روش تحلیل موارد کامل (CCA)

در این روش، سطرهای دارای داده گمشده حذف شدند و حجم نمونه از 108 به 86 کاهش یافت. ضریب سن از 0.660 به 0.706 و ضریب جنسیت از -2.321 به -2.531 تغییر کرد. بنابراین حذف موارد ناقص باعث تغییر برآورد ضرایب شد و همزمان اطلاعات بخشی از نمونه از دست رفت.

```
21 d_cca <- na.omit(d2)  
22  
23 m_cca <- lm(distance ~ age + Sex, data = d_cca)
```

۴-۱۳- حذف سطرهای دارای داده گمشده

روش های مبتنی بر جایگذاری (MI و LOCF)

روش انتقال آخرین مشاهده (LOCF):

در این روش حجم نمونه به 100 رسید. ضرایب به داده کامل نزدیک تر بودند: ضریب سن 0.658 و ضریب جنسیت -2.384 شد. با این حال LOCF از نظر روش شناسی محدودیت دارد، چون مقدار قبلی را تکرار می کند و ممکن است تغییر طبیعی متغیر را کم رنگ کند.

```

25 d_locf <- d2 %>%
26   arrange(Subject, age) %>%
27   group_by(Subject) %>%
28   mutate(distance = na.locf(distance, na.rm = FALSE)) %>%
29   ungroup() %>%
30   na.omit()
31
32 m_locf <- lm(distance ~ age + Sex, data = d_locf)
33

```

۴-۱۴- اجرای locf

روش جایگذاری چندگانه (MI):

در روش جایگذاری چندگانه، ضریب سن 0.734 و ضریب جنسیت -2.575 به دست آمد. این روش علاوه بر حفظ داده‌ها، عدم قطعیت ناشی از گمشدگی را هم در برآورد وارد می‌کند. به همین دلیل از نظر آماری معمولاً از CCA و LOCF معتبرتر در نظر گرفته می‌شود.

```

36
37 d_mi <- d2[, c("distance", "age", "Sex")]
38
39 imp <- mice(
40   d_mi,
41   m = 5,
42   method = "pmm",
43   seed = 123,
44   printFlag = FALSE
45 )
46
47 fit_mi <- with(imp, lm(distance ~ age + Sex))
48
49 pooled_mi <- pool(fit_mi)
50

```

۴-۱۵- روش جایگذاری چندگانه با استفاده از کتابخانه mice

در ادامه به مقایسه روش های به کار گرفته شده می پردازیم:

جهت مقایسه دقت روش های جایگذاری در برآورد پارامترهای مدل، از معیار تورش (Bias) استفاده شد. تورش بر اساس اختلاف برآورد هر روش با مدل مرجع (داده کامل) محاسبه گردید. هرچه مقدار مطلق این تورش کمتر باشد، روش جایگذاری به مقدار واقعی (True Parameter) نزدیک تر بوده و از عملکرد بهتری برخوردار است.

Bias	β_1 (اثر سن بر فاصله دندان)	روش مورد استفاده
0.000	0.660	Full Model
0.046	0.706	CCA(Complete Case Analysis)
- 0.002	0.658	LOCF
0.074	0.734	MI

جدول ۴-۲- برآورد اثر سن بر فاصله دندان

نتایج نشان می دهد که هر سه روش جایگذاری توانسته اند جهت اثر سن را به درستی (مثبت) برآورد کنند. اگرچه روش LOCF از نظر عددی کمترین تورش را نشان داد، اما روش MI (جایگذاری چندگانه) به دلیل حفظ حجم نمونه و لحاظ کردن عدم قطعیت ناشی از گمشدگی، از نظر تئوریک معتبرترین رویکرد برای تحلیل نهایی است. اختلاف برآوردهای به دست آمده در روش های مختلف، ضرورت دقت در انتخاب روش برخورد با داده های گمشده را در مطالعات طولی تایید می کند.

البته دانستن این نکته ضروری است که در داده های با مکانیسم گمشدگی کاملاً تصادفی استفاده از روش locf معمول نیست در این بخش صرفاً جهت مقایسه استفاده نمودیم.

در این مطالعه، با توجه به ماهیت داده های طولی Orthodont و وجود گمشدگی های پراکنده، روش LOCF به گونه ای پیاده سازی شد که آخرین مقدار مشاهده شده برای هر فرد، جایگزین مقادیر گمشده ی بعدی او (اعم از دراپاوت یا گمشده ی میان دوره) گردد.

یافته های پژوهش، نتیجه گیری و پیشنهادها

۱-۵- یافته های پژوهش

بر اساس تحلیل های آماری صورت گرفته و مقایسه روش های مختلف برخورد با داده های گمشده در داده های طولی، یافته های کلیدی این پژوهش به شرح زیر است:

برتری مدل های مبتنی بر درست نمایی: مدل آمیخته خطی (LMM) با کمترین میزان سوگیری ($Bias = -0.66$)، دقیق ترین برآورد را نسبت به مقدار واقعی پارامتر هدف ارائه داد. این یافته نشان دهنده توانمندی این مدل در استفاده بهینه از تمامی اطلاعات موجود، اعم از اطلاعات ناقص و کامل، است.

عملکرد مطلوب جایگذاری چندگانه: روش جایگذاری چندگانه (MI)، پس از مدل های آمیخته، رتبه دوم را از نظر دقت برآورد کسب کرد. این روش با در نظر گرفتن عدم قطعیت ناشی از داده های گمشده، بسیار بهتر از روش های سنتی عمل نمود.

سوگیری شدید در روش های ساده: روش های LOCF و CCA، به دلیل فروض غیرواقع بینانه، مانند ثابت ماندن وضعیت فرد پس از خروج یا حذف کامل اطلاعات آزمودنی، منجر به برآوردهای سوگیرانه و غیردقیق شدند؛ به ویژه روش LOCF که شیب تغییرات زمان واکنش را بسیار کمتر از مقدار واقعی برآورد کرد.

۲-۵- نتیجه‌گیری

نتایج این مطالعه نشان می‌دهد که در تحلیل داده‌های طولی، انتخاب روش برخورد با داده‌های گمشده تأثیر تعیین‌کننده‌ای بر نتایج نهایی و تفسیرهای بالینی و آماری دارد. با توجه به اینکه در مطالعات انسانی، پدیده ریزش (Dropout) اجتناب‌ناپذیر است، استفاده از روش‌های ساده‌ای مانند حذف کامل موارد یا جایگذاری با آخرین مشاهده می‌تواند به نتایج گمراه‌کننده منجر شود.

در نهایت، این پژوهش تأیید می‌کند که اگر مکانیسم گمشدگی از نوع تصادفی (MAR) باشد، مدل‌های آمیخته خطی (LMM)، به دلیل ماهیت درون‌ساختاری خود در مواجهه با داده‌های نامتوازن، بهترین گزینه برای تحلیلگران آمار محسوب می‌شوند.

۳-۵- پیشنهادها

الف) پیشنهادهای کاربردی

- به پژوهشگران حوزه علوم پزشکی و علوم اجتماعی پیشنهاد می‌شود که در تحلیل داده‌های طولی، به جای استفاده از روش‌های سنتی، مانند LOCF، از مدل‌های آمیخته خطی یا جایگذاری چندگانه استفاده کنند تا اعتبار نتایج آن‌ها افزایش یابد.
- توصیه می‌گردد پیش از تحلیل داده‌ها، مکانیسم گمشدگی تا حد امکان بررسی شود و تحلیل‌های حساسیت لازم انجام گیرد تا مناسب‌ترین روش برای تحلیل انتخاب گردد.

ب) پیشنهادهایی برای پژوهش‌های آتی

- پیشنهاد می‌شود در مطالعات آینده، عملکرد این روش‌ها در شرایطی که توزیع متغیر پاسخ غیرنرمال باشد، مانند توزیع پواسون یا دوجمله‌ای، مورد ارزیابی قرار گیرد.

- بررسی عملکرد روش‌های جایگذاری بازگشتی و روش‌های مبتنی بر یادگیری ماشین، مانند جنگل تصادفی (Random Forest)، در مقایسه با روش‌های کلاسیک آماری در داده‌های گمشده طولی می‌تواند موضوع جذابی برای پژوهش‌های بعدی باشد.
- ارزیابی حساسیت نتایج نسبت به فرض MNAR (گمشدگی غیرتصادفی) و استفاده از مدل‌های آمیخته الگو (Pattern-Mixture Models) نیز به عنوان یک گام تکمیلی پیشنهاد می‌گردد.

مرجع ها

Analysis of Longitudinal Data with Drop-out Objectives, Assumptions and a Proposal (Peter Diggle & Daniel Farewell)

Missing data methods in longitudinal studies: a review Joseph G. Ibrahim & Geert Molenberghs

Longitudinal Data Analysis : Donald Hedeker & Robert D. Gibbons University of Illinois at Chicago

Multiple Imputation for Longitudinal Data: A Tutorial : Rushani Wijesuriya & Margarita Moreno-Betancur & John B. Carlin

Rubin DB. Multiple Imputation for Non-response in Surveys.
New York: John Wiley & Sons; ۱۹۸۷

انواع گمشدگی در مطالعات طولی و روش های مبنی بر درستنمایی برای تحلیل آنها

فرید زایری و علیرضا اکبرزاده باغبان و مژگان کاظم زاده